


Machine Learning HW4: DCGAN

tags: Machine Learning

Colab Link

<https://colab.research.google.com/drive/1xZRSFKsIntqo8SdZ6SYd-beiHv9P47La?usp=sharing>

Experimental results




訓練各階段 loss 表

Step	lossG	lossD
0	5.108	1.485
200	4.421	0.608
1000	3.716	0.551
2500	3.308	0.317
5000	0.949	1.462

Answers

Q1


Compare the visualization images after step 0, 200, 1000, 2500, 5000.




Step 0



Step 200



Step 1000




Step 2500



Step 5000

Q2

Why can't we see the typical loss decreasing in generator and discriminator's loss curve?



- 以上圖顯示出，G loss 為 D 網路判斷 G 生成的圖片的是否真實的概率，對 G 網路而言，愈接近低愈好，代表判斷網路判斷為真。

- 而 D loss curve 為 D 網路對於判斷真實圖片跟生成圖片的 loss 加總，一方面希望判斷真實圖片 loss 愈低愈好，但又希望判斷生成圖片的 loss 愈高愈好，所以加總起來會顯示震盪且趨勢接近水平。

Q3

Generating Fake Images



$N(0, 1)$



$N(-10, 1)$



$U(0, 1)$

Q4

Why the result of Q3.2 looks so weird, i.e., Why our generator fails at generating images using latent vector following distribution $N(-10, 1)$?

如果將分布的平均值設定的過於小會造成生成出來的圖片很難找到最大的 likelihood，造成生成器很難判斷生成的圖片是否為需要的圖片，造成生成器不知道該如何生成可以騙過分辨器的圖片。

Q5

Why the result images of Q3.3 looks so similar to each other?

因為使用的是均勻分布，也就是輸入進去的 noise 是均勻分散的，這導致 generator 難以生成可以騙過分辨器的假圖片。

Conclusion

透過 GAN 生成對抗網路可以從無到有產生人臉的圖片，而且也知道生成器所生成的圖片會愈來愈接近常態分布，且愈來愈可以騙過分辨器，所以挑選正確的 noise 分布方式對生成器非常重要，其中平均值為 0 且標準差為 1 的常態分佈效果最好。

透過 GAN 生成對抗網路可以應用到很多方面，像是圖片風格轉換等等，而且最大優點就是不用再花費多餘人力去標記資料，由網路自行生成及分辨，達到自動生成的強

大功用。

Discussion

對於範例程式中把分辨器對於真假圖片的 loss 加總計算，感到不解，因為分開顯示曲線可以更好地顯示出訓練的狀態，判斷到底分辨器對於真假圖片的判斷力如何，特別是對假圖片，要分辨出為假的更好，但是合併兩者後，就難以判斷兩者的訓練分辨情況了。